

Universidad Pontificia Comillas

ICAI

LABORATORIO 1

Aprendizaje por refuerzo

Lydia Ruiz Martínez, Pablo Tuñón Laguna, Alberto Velasco Rodríguez

ECUACIONES DE BELLMAN, POLICY Y VALUE ITERATION



Curso 2025-2026

Índice

1. Introducción	2
2. Trabajo previo	2
3. Policy Iteration	3
4. Value Iteration	5
5. MDP Estocástico	6

1. Introducción

En este laboratorio se exploran las bases del aprendizaje por refuerzo a través de las ecuaciones de Bellman y los algoritmos de programación dinámica. Las ecuaciones de Bellman son la base teórica para hallar políticas óptimas en procesos de decisión de Markov (MDPs), ya que expresan el valor de un estado como la suma de la recompensa inmediata así como el valor esperado del estado siguiente.

Se implementan y comparan dos algoritmos clásicos: Policy Iteration, que alterna evaluaciones de política y mejora hasta converger a la política óptima frente a Value Iteration, que actualiza directamente los valores de estado usando la ecuación de optimalidad de Bellman. Además, se analiza el comportamiento de dichos algoritmos tanto en entornos deterministas como estocásticos, evaluando su sensibilidad a parámetros clave como el factor de descuento γ y la tolerancia de convergencia θ .

El trabajo se estructura en cuatro secciones: primero se derivan analíticamente las ecuaciones de Bellman para estados específicos bajo una política estocástica, posteriormente se implementa Policy Iteration y Value Iteration analizando su convergencia para finalmente comparar el comportamiento en entornos deterministas versus estocásticos.

2. Trabajo previo

En el trabajo previo se quiere determinar, en función de r_s , las ecuaciones de Bellman para los estados s_{13} , s_{17} y s_{11} bajo una política estocástica equiprobable (en cada estado, cada acción tiene probabilidad 0.5). El objetivo consiste en analizar cómo varía el valor de los estados y qué condiciones sobre r_s garantizan que la política óptima siga el camino deseado.

Cálculos detallados

Estado s_{13} :

$$a_1 : r_s + 0,9(r_s + 0,9 \cdot 5) = 1,9r_s + 4,05, \quad a_2 : 5$$

Para que la política óptima elija el camino al objetivo:

$$1,9r_s + 4,05 < 5 \Rightarrow r_s < \frac{0,95}{1,9} \approx 0,5.$$

Estado s_{17} :

$$a_1 : r_s + 0,9 \cdot 5 = r_s + 4,5, \quad a_2 : r_s + 0,9 \cdot 5 = r_s + 4,5$$

Ambas acciones proporcionan el mismo valor, por tanto *existen múltiples políticas óptimas*. No se impone restricción sobre r_s .

Estado s_{11} :

$$a_1 : -5, \quad a_2 : r_s + 0,9 \cdot 5 = r_s + 4,5$$

Para que la política no prefiera caer en el obstáculo:

$$r_s + 4,5 > -5 \Rightarrow r_s > -9,5.$$

Conclusión

Combinando las condiciones:

$$-9,5 < r_s < 0,5$$

- Si $r_s \in \{-3, -1\}$, el agente sigue siempre el camino más corto.
- En s_{17} hay políticas óptimas múltiples, pues ambas acciones son equivalentes.
- Si r_s es demasiado positivo ($> 0,5$), el agente podría alargar el camino sin perder valor.
- Si r_s es demasiado negativo ($< -9,5$), el agente preferiría caer en estados terminales no deseados.

3. Policy Iteration




Figura 1: Evolución del *suboptimality gap* (determinista).




Figura 2: Evolución del *suboptimality gap* (estocástico).

En estas gráficas se puede observar que el *suboptimality gap* cae de forma constante hasta llegar a 0 en la tercera iteración y se mantiene en la cuarta.

- En el caso determinista, el gap pasa de $\sim 8,5$ a $6,0$, y finalmente a 0.
- En el caso estocástico, el gap baja de $\sim 5,1$ a $0,8$ y después también converge a 0.

En resumen, la política óptima se alcanza muy rápido (3 iteraciones).




Figura 3: Actualización de V_s por estado en PI (determinista).




Figura 4: Actualización de V_s por estado en PI (estocástico).

Se puede observar cómo cambian los valores por estado. En el determinista, los picos de diferencia aparecen sobre todo cerca de la meta y de los obstáculos, y van desapareciendo hasta quedar planos. En el estocástico, los cambios se reparten más suavemente y alcanzan zonas más alejadas, lo cual refleja el efecto de la incertidumbre en las transiciones.

Sensibilidad a γ y θ .

- Con γ más alto, los caminos largos pesan más, pero como cada paso tiene coste negativo, la política sigue prefiriendo los caminos cortos. Sí que se nota que la convergencia es más lenta.
- Con una tolerancia θ más estricta, es decir, un valor de θ menor, se necesitan más iteraciones internas de evaluación antes de mejorar la política. El número de iteraciones externas se mantiene, pero tarda un poco más.

4. Value Iteration




Figura 5: Actualización de V_s en VI (determinista).




Figura 6: Actualización de V_s en VI (estocástico).

Value Iteration actualiza directamente los valores con la ecuación de optimalidad. Los gráficos muestran picos en estados cercanos a la meta y a los obstáculos, mientras que en el resto los cambios son casi nulos porque ya están estabilizados.

Sensibilidad a γ y θ .

■ Parámetro γ :

- Si aumentamos γ (más cerca de 1), las recompensas futuras pesan más.
- Esto no cambia la política óptima en este entorno (sigue siendo el camino corto, porque cada paso tiene un coste negativo), pero sí ralentiza la convergencia: los valores de los estados dependen de horizontes más largos y los cambios en V_s se propagan más despacio.
- Con γ más bajo, la convergencia es más rápida, pero la política puede ser menos sensible a recompensas lejanas.

■ Tolerancia θ :

- Igual que en PI, una θ más estricta (más pequeña) implica que VI seguirá iterando más tiempo hasta que los cambios en V_s sean muy pequeños.
- Esto aumenta el número de *iteraciones externas* necesarias.
- La política final no cambia (sigue siendo la óptima), aunque se gana precisión en los valores.

Cuando el agente aprende con Policy Iteration y con Value Iteration, en ambos casos llega a la misma solución: la política óptima. Las políticas obtenidas son equivalentes, salvo posibles diferencias menores en cómo se resuelven empates, pero su desempeño es idéntico. Policy Iteration suele necesitar pocas iteraciones externas (3 en este entorno) para estabilizar la política. Value Iteration requiere más iteraciones globales, aunque cada una es más ligera en cómputo. En la práctica, los tiempos de convergencia de ambos métodos resultan similares para este problema.

5. MDP Estocástico

Con $p_{\text{éxito}} = 0,8$ y $p_{\text{fallo}} = 0,2$ en el entorno estocástico, el proceso de aprendizaje del agente sigue siendo estable: el suboptimality gap también cae a 0 en tres iteraciones, igual que en el caso determinista. La diferencia es que la primera iteración reduce gran parte del error (de $\sim 5,1$ a $0,8$), debido a que las transiciones probabilísticas suavizan los retornos. Los cambios en los valores V_s se reparten de forma más uniforme por el espacio de estados, alcanzando zonas más alejadas que en el entorno determinista. Aun así, la política óptima resultante vuelve a ser el camino corto, ya que cada paso tiene un coste negativo. En resumen, la incertidumbre no modifica la solución final, pero hace que el proceso de aprendizaje sea más progresivo y con transiciones de valor más suaves que en el entorno determinista.