

Universidad Pontificia Comillas

ICAI

LABORATORIO 2

Aprendizaje por refuerzo

Lydia Ruiz Martínez, Pablo Tuñón Laguna, Alberto Velasco Rodríguez

RL TABULAR SIN MODELO



Curso 2025-2026

Índice

1. Introducción	2
2. SARSA	2
2.1. Implementación	2
2.2. Convergencia de $Q(s, a)$	2
2.3. Evolución de valores de Q	3
2.4. Pasos medios por episodio	3
3. Q-learning	4
3.1. Implementación	4
3.2. Convergencia de $Q(s, a)$	4
3.3. Evolución de valores de Q	4
3.4. Pasos medios por episodio	5
4. Comparación entre SARSA y Q-learning	6
5. Conclusiones	6

1. Introducción

En este informe se analiza la evolución y convergencia de los valores de acción $Q(s, a)$ utilizando los algoritmos de aprendizaje por refuerzo **SARSA** y **Q-learning**. El estudio se centra en los estados **s13** y **s22**, evaluando la aproximación de los valores aprendidos a los valores óptimos obtenidos mediante *Policy Iteration* (PI) y *Value Iteration* (VI). Asimismo, se analiza el efecto de los hiperparámetros sobre la dinámica del aprendizaje.

2. SARSA

2.1. Implementación

El algoritmo SARSA fue implementado respetando el esquema propuesto, actualizando los valores $Q(s, a)$ siguiendo la política ϵ -greedy. Las actualizaciones se realizan conforme a la siguiente ecuación:

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha [r_{t+1} + \gamma Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t)]$$

2.2. Convergencia de $Q(s, a)$

Se evalúa la convergencia de los siguientes pares estado-acción:

- $Q(13, \text{arriba-derecha})$
- $Q(13, \text{abajo-derecha})$
- $Q(22, \text{arriba-derecha})$
- $Q(22, \text{abajo-derecha})$

Los valores obtenidos se comparan con los valores reales de Policy Iteration (PI) y Value Iteration (VI):

Cuadro 1: Comparación de valores $Q(s, a)$ en SARSA

Estado-Acción	Valor SARSA	Valor Real (PI/VI)	Error Absoluto
$Q(13, \uparrow \rightarrow)$	2.14	2.15	0.01
$Q(13, \downarrow \rightarrow)$	5.00	5.00	0.00
$Q(22, \uparrow \rightarrow)$	2.15	2.15	0.00
$Q(22, \downarrow \rightarrow)$	-5.44	-5.50	0.06

Se puede ver que el error acaba siendo ínfimo en los 4 pares, habiendo sólo dos pares que no consiguen un error de 0. En concreto, estos pares son los de la acción menos desable para cada estado, debido a que la política ϵ -greedy de comportamiento de Sarsa fomenta investigar más las opciones de máximo valor.

2.3. Evolución de valores de Q

En la figura 1 se puede observar que a partir del episodio 400 no aparecen apenas cambios en los valores de Q. Alcanzando ese error tan bajo alrededor a ese número de episodios. Además, llama la atención la variabilidad del par (22, $\uparrow \rightarrow$) cuyo valor de Q cae por momentos.




Figura 1: Evolución de $Q(s, a)$ con episodios (SARSA)

2.4. Pasos medios por episodio

En la figura 2 se puede ver que el número de episodios respecto al número de pasos forma prácticamente una recta. Aunque la pendiente va aumentando ligeramente, indicando que los episodios van durando menos pasos según se van completando. De hecho, la curva deja aumentar en pendiente a partir del episodio 400, debido a la convergencia de los valores de Q. Podemos obtener el número de pasos medio que tarda en finalizar un episodio con el número total de pasos entre el número de episodios, lo cual es aproximadamente $3000/1000 = 3$.




Figura 2: Episodios exitosos vs pasos (SARSA)

3. Q-learning

3.1. Implementación

El algoritmo Q-learning se implementó en el archivo `q_learning.py`. A diferencia de SARSA, Q-learning actualiza $Q(s, a)$ utilizando la acción con el valor máximo en el siguiente estado:

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_{t+1} + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t) \right]$$

3.2. Convergencia de $Q(s, a)$

Se evaluaron los mismos pares estado-acción que en SARSA.

Cuadro 2: Comparación de valores $Q(s, a)$ en Q-learning

Estado-Acción	Valor Q-learning	Valor Real (PI/VI)	Error Absoluto
$Q(13, \uparrow \rightarrow)$	1.52	2.15	0.63
$Q(13, \downarrow \rightarrow)$	5.00	5.00	0.00
$Q(22, \uparrow \rightarrow)$	2.15	2.15	0.00
$Q(22, \downarrow \rightarrow)$	-5.50	-5.50	0.00

Se obtiene un error de 0 en 3 de los pares. Sin embargo, el par $(13, \uparrow \rightarrow)$ obtiene un error de 0.63, mucho mayor a cualquiera obtenido con SARSA. Al igual que en SARSA, sólo se obtiene error en el caso de la acción menos deseable.

3.3. Evolución de valores de Q




Figura 3: Evolución de $Q(s, a)$ con episodios (Q-learning)

En la figura 3 se puede observar que Q-learning es más estable que SARSA. Además, los valores de Q para las acciones más deseables convergen muy rápidamente al valor real. Por otro lado, el valor de Q para las acciones menos deseables tarda bastante en converger (800 episodios).

3.4. Pasos medios por episodio

En la figura 4 podemos ver que el número de episodios exitosos respecto al número de pasos forma una recta de pendiente $4300/1000 = 4.3$. Con Q-learning los episodios duran bastante más que con SARSA. Al tomar la acción con mayor Q se evita explorar opciones que a priori parecen peores, pero que pueden resultar mejores. Un ejemplo de esto es preferir acabar el episodio cuanto antes, porque intentar llegar al estado 19 acaba incurriendo en una mayor pérdida, algo que Q-learning tiende a no ver.




Figura 4: Episodios exitosos vs pasos (Q-learning)

4. Comparación entre SARSA y Q-learning

Cuadro 3: Comparación de desempeño

Métrica	SARSA	Q-learning
Velocidad de convergencia	400	800
Velocidad de convergencia (acción óptima “clara”)	200	100
Exploración	Mejor	Peor
Error final	0.07	0.063

Observaciones

- SARSA mostró una convergencia más rápida para el global de los valores.
- Q-learning obtuvo una convergencia más rápida para los valores de Q de la acción óptima de estados donde se debe intentar maximizar el valor a corto plazo.

5. Conclusiones

En este laboratorio se ha analizado el comportamiento de los algoritmos SARSA y Q-learning, ambos pertenecientes a los métodos de aprendizaje por diferencia temporal (*Temporal-Difference Learning*). Estos métodos combinan las ventajas del aprendizaje por Monte Carlo (MC) y de la Programación Dinámica (DP), ya que aprenden directamente de la experiencia sin disponer de un modelo del entorno, actualizando sus estimaciones de forma incremental a partir de recompensas observadas y de los valores estimados de los estados sucesores.

El algoritmo SARSA, de tipo *on-policy*, aprende la función de acción-valor siguiendo la política de comportamiento ε -greedy, actualizando sus estimaciones con las transiciones realmente ejecutadas. Esto le permite adaptarse de forma más conservadora a la exploración, resultando en un aprendizaje más estable y robusto, aunque potencialmente más lento en alcanzar el valor óptimo. En nuestros resultados, SARSA muestra una convergencia rápida y suave, con un error muy bajo respecto a los valores obtenidos mediante *Policy Iteration* (PI) y *Value Iteration* (VI).

Por otro lado, Q-learning es un algoritmo *off-policy* que actualiza sus valores de acción-estado utilizando la ecuación de optimalidad de Bellman, de manera independiente de la política de comportamiento. Esto le permite aproximar directamente la función óptima Q^* , pero introduce un sesgo de maximización al usar el mismo estimador tanto para seleccionar como para evaluar la acción con mayor valor esperado. En los experimentos realizados, Q-learning alcanza los valores óptimos en menos pasos para las acciones con mayor recompensa inmediata, pero presenta una mayor variabilidad y sobrevaloración en las acciones subóptimas, especialmente durante las primeras fases del aprendizaje.

Ambos algoritmos logran aproximar los valores óptimos de $Q(s, a)$ dados suficientes episodios. Sin embargo, para estados donde la acción óptima a largo plazo difiere de la acción aparentemente mejor a corto plazo, Q-learning puede tener dificultades. Esto se debe a que Q-learning tarda más en refinar los valores de Q para las acciones que no son preferibles a primera vista, debido a su carácter *off-policy* y a la tendencia a sobrevalorar las recompensas inmediatas. SARSA, en cambio, al aprender siguiendo su propia política de comportamiento, tarda menos en converger de forma global y genera políticas más seguras y coherentes.

En definitiva, ambos algoritmos convergen hacia la política óptima π^* cuando se cumplen las condiciones de exploración suficientes y una reducción progresiva del parámetro ε , pero difieren en su robustez y comportamiento transitorio durante el proceso de aprendizaje.