

Universidad Pontificia Comillas

ICAI

LABORATORIO 2

Aprendizaje por refuerzo

Lydia Ruiz Martínez, Pablo Tuñón Laguna, Alberto Velasco Rodríguez

RL TABULAR SIN MODELO



Curso 2025-2026

Índice

1. Introducción	2
2. SARSA	2
2.1. Implementación	2
2.2. Convergencia de $Q(s, a)$	2
2.3. Evolución con distintos hiperparámetros	2
3. Q-learning	3
3.1. Implementación	3
3.2. Convergencia de $Q(s, a)$	4
3.3. Evolución con distintos hiperparámetros	4
4. Comparación entre SARSA y Q-learning	5
5. Conclusiones	5

1. Introducción

En este informe se analiza la evolución y convergencia de los valores de acción $Q(s, a)$ utilizando los algoritmos de aprendizaje por refuerzo **SARSA** y **Q-learning**. El estudio se centra en los estados **s13** y **s22**, evaluando la aproximación de los valores aprendidos a los valores óptimos obtenidos mediante *Policy Iteration* (PI) y *Value Iteration* (VI). Asimismo, se analiza el efecto de los hiperparámetros sobre la dinámica del aprendizaje.

2. SARSA

2.1. Implementación

El algoritmo SARSA fue implementado respetando el esquema propuesto, actualizando los valores $Q(s, a)$ siguiendo la política ϵ -greedy. Las actualizaciones se realizan conforme a la siguiente ecuación:

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha [r_{t+1} + \gamma Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t)]$$

2.2. Convergencia de $Q(s, a)$

Se evalúa la convergencia de los siguientes pares estado-acción:

- $Q(13, \text{arriba-derecha})$
- $Q(13, \text{abajo-derecha})$
- $Q(22, \text{arriba-derecha})$
- $Q(22, \text{abajo-derecha})$

Los valores obtenidos se comparan con los valores reales de PI y VI:

Cuadro 1: Comparación de valores $Q(s, a)$ en SARSA

Estado-Acción	Valor SARSA	Valor Real (PI/VI)	Error Absoluto
$Q(13, \uparrow \rightarrow)$	—	—	—
$Q(13, \downarrow \rightarrow)$	—	—	—
$Q(22, \uparrow \rightarrow)$	—	—	—
$Q(22, \downarrow \rightarrow)$	—	—	—

2.3. Evolución con distintos hiperparámetros

Se analizaron diferentes configuraciones de los hiperparámetros α (tasa de aprendizaje), γ (factor de descuento), y ϵ (exploración).




Figura 1: Evolución de $Q(s, a)$ con episodios (SARSA)




Figura 2: Episodios exitosos vs pasos (SARSA)

3. Q-learning

3.1. Implementación

El algoritmo Q-learning se implementó en el archivo `q_learning.py`. A diferencia de SARSA, Q-learning actualiza $Q(s, a)$ utilizando la acción con el valor máximo en el siguiente estado:

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_{t+1} + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t) \right]$$

3.2. Convergencia de $Q(s, a)$

Se evaluaron los mismos pares estado-acción que en SARSA.

Cuadro 2: Comparación de valores $Q(s, a)$ en Q-learning

Estado-Acción	Valor Q-learning	Valor Real (PI/VI)	Error Absoluto
$Q(13, \uparrow \rightarrow)$	—	—	—
$Q(13, \downarrow \rightarrow)$	—	—	—
$Q(22, \uparrow \rightarrow)$	—	—	—
$Q(22, \downarrow \rightarrow)$	—	—	—

3.3. Evolución con distintos hiperparámetros




Figura 3: Evolución de $Q(s, a)$ con episodios (Q-learning)




Figura 4: Episodios exitosos vs pasos (Q-learning)

4. Comparación entre SARSA y Q-learning

Cuadro 3: Comparación de desempeño

Métrica	SARSA	Q-learning
Velocidad de convergencia	—	—
Estabilidad	—	—
Precisión final	—	—
Sensibilidad a ϵ	—	—

Observaciones

- Q-learning mostró una convergencia más rápida, pero menos estable en ciertos casos.
- SARSA fue más conservador, lo que puede ser ventajoso en entornos estocásticos.
- La elección del valor de ϵ fue crucial para ambas estrategias.

5. Conclusiones

Ambos algoritmos logran aproximar los valores óptimos de $Q(s, a)$ dados suficientes pasos de entrenamiento. La elección de hiperparámetros tiene un impacto significativo sobre la eficiencia del aprendizaje. Se recomienda ajustar cuidadosamente los valores de α , γ y ϵ según el entorno específico y la política deseada.

Apéndice

- Código fuente: `sarsa.py`, `q_learning.py`
- Parámetros de entrenamiento utilizados
- Gráficos adicionales